

コードの時系列変化を考慮した 保守性低下の要因分析と改善

鈴木研究室 笹川 尋翔

目次

1. 背景と関連研究
2. 目的
3. データ分析の流れ
4. 分析手法
5. 結果
6. 考察
7. 今後の見通し

1. 背景と関連研究

1.1 ソフトウェア開発における課題




図1 メソッド構造の変化

76%の開発者がリファクタリングによるバグ混入のリスクを認識 [1]

ソフトウェアの構造の変化に伴い、クラスや関数の理解が困難に

[1] Microsoft Research, "An Empirical Study of Refactoring Challenges and Benefits at Microsoft"

1.2 関連研究

- レビューコメントを収集し、保守性の低下リスクを分析^[2]
- 静的解析ツールを用いてコードの改善策を提示^[3]
- コードメトリクスを用いたバグ予測により、コード品質を改善^[4]

[2] X.Han et al., "Understanding Code Smell Detection via Code Review: A Study of the OpenStack Community"

[3] S.Romano et al., "Do Static Analysis Tools Affect Software Quality when Using Test-driven Development?"

[4] R.Ferenc et al., "An automatically created novel bug dataset and its validation in bug prediction"

2. 目的

2 目的

- 時系列変化量を用いたバグ予測精度の向上
 - コードメトリクス（例: メソッドの複雑度・凝集度）の変化量を導入・分析
- バグの特徴とメトリクスの関係性の解明
 - バグの特徴を体系的に整理し、保守性とのつながりを明確化
 - バグの性質ごとにコードの改善策を示す

3. データ分析の流れ

3.1 概要




図2 データ分析の流れ

1. 時系列変化量を追加
2. テキストデータをカテゴリカル変数に変換
3. 特徴量の追加前と追加後のデータを用いて機械学習モデルを学習

3.2 時系列変化量の追加




図3 ソフトウェア構造の変化

- 単純な時系列データとして、コード行数・トークン数・循環的複雑度の変化量をデータセットに追加

3.2 カテゴリカル変数の導入

- クラスやメソッドの識別子を単語ごとに分解
 - 単語の出現率などの類似性に基づいて学習できるようにする
- メソッドに対する操作（例: 追加、削除）を表す変数を導入
 - 変化量が欠損値であったときに、その理由を説明できるようにする

3.3 機械学習モデルの構築




図4 バグの2値分類の概要

- 決定木を複数生成し、多数決で境界線を決定

4. 分析手法

4.1 プロジェクトの選定

表1 選定したプロジェクト

プロジェクト	役割
antlr4	構文解析ツール
BroadleafCommerce	Webアプリフレームワーク
ceylon-ide-eclipse	IDEプラグイン
elasticsearch	全文検索エンジン
hazelcast	インメモリデータベース
oryx	機械学習フレームワーク

4.2 プロジェクトの分析

分析手順

1. 特徴量重要度（Feature Importance）を算出
2. ヒストグラムで特徴量分布を確認
3. Partial Dependence Plot（PDP）を用いて分類傾向を把握
4. 決定木で分類の流れを可視化し、判断の基準と信頼性を確認

5. 結果

5.1 特徴量重要度




図5 hazelcastの特徴量重要度

- トークン数・コード行数の変化量、Halsteadメトリクス、Maintainability Indexの重要度が高い

5.2 特徴量分布




図6 ceylon-ide-eclipseの特徴量分布

- 変化量やHalstead系は分散が小さく、Maintainability Indexは分散が大きい

5.3 PDP分析




図7 elasticsearchのPDP

- ほとんどの特徴量において、陽性クラスの予測確率が0.5未満

5.4 決定木分析




図8 elasticsearchの決定木

- 陰性クラスの子ノードのジニ不純度が比較的低い

5.5 評価指標の測定

表2 評価指標の値の変化

プロジェクト	F1スコア (変更前)	F1スコア (変更後)
ceylon-ide-eclipse	0.39	0.49
elasticsearch	0.62	0.72
hazelcast	0.67	0.71
antlr4	0.45	0.48
oryx	0.33	0.39

モデルの予測性能が改善される傾向があることを確認

6. 考察

6 考察

陰性クラス予測の改善

リファクタリングによるメトリクスの減少傾向を確認できた

消去法的な分類がF1スコアの改善に寄与

さらなる精度向上に向けて

PDPや決定木を見ると、陽性クラスの予測確率が低い

バグの混入理由が多様であることが影響している可能性

7. 今後の見通し

7 今後の見通し

陽性クラスの詳細な分類による因果関係の解明

バグ混入と保守性メトリクスに関連性が不明確であるため

バグの体系的分類によるパターンの識別

Orthogonal Defect Classification (ODC) のような分析手法を活用

バグの特徴とコードメトリクスの時系列変化の関連性を示す

まとめ

半数のプロジェクトで有意差があり、F1スコアが最大0.1向上

コードメトリクスの変化量を組み合わせることで、より効果的なバグ分類ができるようになった

今後は陽性クラスの分類精度を高め、品質改善に役立つコードの特徴を捉えたい